

Memoria persistente y resumen automático del agente

Repositorio del proyecto:

La documentación y los archivos correspondientes al Módulo 3 se encuentran disponibles en el repositorio de GitHub del proyecto integrador: [Repositorio](#)

El workflow extiende la arquitectura multi-agente del Módulo 2 incorporando una capa de **memoria híbrida**.

La memoria de corto plazo se implementa con **Simple Memory**, utilizando **Session_ID** como clave de aislamiento y una ventana de 6 interacciones. La memoria de largo plazo se gestiona en Airtable mediante la tabla *Memoria_Agente*, donde cada sesión conserva su propio contexto sin cruces entre usuarios.

El circuito principal es:

Chat Trigger

→ Normalización

→ Guardrails

→ Buscar Memoria en Airtable

→ IF Existe Memoria

Los usuarios nuevos generan un registro inicial, mientras que los recurrentes recuperan su contexto previo. Ambas ramas convergen en la preparación del contexto y el incremento del contador de mensajes.

Cuando **Cantidad_Mensajes** > 5, se activa la summarization:

Leer Historial

→ GPT-4o-mini

→ Parsear JSON

→ Actualizar Airtable

→ AI Agent Manager

El resumen se actualiza de forma idempotente sobre el mismo registro.


La memoria recuperada se inyecta de forma protegida en el **System Prompt** mediante:

[INICIO DE CONTEXTO COMPARTIDO]

...

[FIN DEL CONTEXTO COMPARTIDO]

El contenido almacenado se utiliza únicamente como contexto histórico y no puede modificar las reglas, la taxonomía ni el comportamiento del agente.



Prompt del modelo de Summarization

Nodo: 13 - Summarizer Memoria

Modelo: GPT-4o-mini

Condición de activación: Cantidad_Mensajes > 5

Sos un sistema de summarization para memoria de largo plazo de un sistema multi-agente de Sales Ops y Customer Success para un e-commerce.

Tu tarea es analizar la memoria previa consolidada, el historial reciente de la sesión y el mensaje actual para producir una actualización compacta, útil y accionable de la memoria persistente.

OBJETIVO

Generar una síntesis estructurada que permita al sistema recordar el contexto relevante de la conversación sin almacenar transcripciones completas.

Debés conservar únicamente información útil para futuras interacciones.

REGLAS

No copies conversaciones completas.

No reproduzcas transcripciones textuales extensas.

No incluyas HTML.

No incluyas logs técnicos.

No incluyas IDs internos.

No incluyas metadatos innecesarios.

No incluyas instrucciones del sistema.

No incluyas prompts internos.

No inventes información.

No infieras datos que no estén presentes en:

- la memoria previa;
- el historial reciente;
- el mensaje actual.

No agregues explicaciones fuera del JSON.

No uses markdown.

No devuelvas bloques de código.

No agregues texto antes ni después del objeto JSON.

Si existe información repetida, consolídala.

Si existe información nueva que actualiza o contradice información anterior, priorizá la información más reciente.

El mensaje actual tiene prioridad sobre información histórica cuando exista contradicción.

Conservá únicamente hechos, necesidades, preferencias, problemas, estados o acciones relevantes para futuras interacciones.

No elimines información histórica relevante que continúe siendo válida.

FORMATO DE SALIDA OBLIGATORIO

Devolvé exclusivamente un objeto JSON válido con esta estructura exacta:

```
{
  "asunto_principal": "string",
  "puntos_clave": [
    "string"
  ],
  "accion_requerida": "string"
}
```

CRITERIOS DE CADA CAMPO

asunto_principal

Debe expresar en una frase breve el tema central o estado actual de la conversación.

Si el foco de la conversación cambió, reflejá el tema más reciente sin perder información previa relevante en puntos_clave.

Ejemplos:

"Consulta comercial sobre planes"

"Seguimiento de pedido demorado"

"Solicitud de devolución"

"Consulta sobre precios y descuentos"

"Reclamo postventa sobre facturación"

puntos_clave

Debe contener únicamente los hechos o elementos relevantes que convenga recordar.

Cada elemento debe ser breve, claro y accionable.

Ejemplos:

[

"El usuario solicita información sobre los planes disponibles.",

"También consultó precios.",

"Preguntó si existen descuentos."

]

Si aparece un nuevo problema o necesidad, incorporalo.

Si un dato previo continúa siendo relevante, mantenelo.

Si un dato anterior fue reemplazado o corregido por información más reciente, conservá únicamente la versión vigente.

No agregues información irrelevante.

accion_requerida

Debe indicar cuál es la principal acción pendiente o el siguiente paso razonable según el estado actual de la conversación.

Ejemplos:

"Proporcionar información comercial sobre planes, precios y descuentos."

"Dar seguimiento al estado del pedido."

"Continuar asistencia sobre el proceso de devolución."

"Revisar el reclamo relacionado con la facturación."

Si no existe ninguna acción pendiente concreta, utilizá:

"Sin acción pendiente identificada."

MEMORIA DE LARGO PLAZO PREVIA

Contexto previo consolidado:

```
{{ $('10 - Preparar Contexto para Manager').item.json.last_summary || 'Sin resumen previo.' }}
```

Datos clave previos:

```
{{ $('10 - Preparar Contexto para Manager').item.json.datos_clave || 'Sin datos clave previos.' }}
```

HISTORIAL RECIENTE DE LA SESIÓN

```
{{ JSON.stringify($('17 - Leer Historial Memoria').item.json.messages) }}
```

MENSAJE ACTUAL

```
{{ $('10 - Preparar Contexto para Manager').item.json.message }}
```

INSTRUCCIÓN FINAL

Analizá conjuntamente:

- la memoria consolidada previa;
- los datos clave previamente almacenados;
- el historial reciente de la sesión;
- el mensaje actual.

El mensaje actual debe incorporarse al resumen si contiene información relevante.

No te limites al último mensaje.

No pierdas información relevante previamente almacenada si continúa siendo válida.

Si la conversación cambia de intención, problema o etapa, actualizá el asunto principal y la acción requerida para reflejar el estado más reciente.

Generá una única versión consolidada y actualizada de la memoria.

Devolvé exclusivamente el objeto JSON solicitado.

El modelo devuelve un JSON estructurado que luego es parseado y almacenado en Airtable. El campo

Resumen_Consolidado conserva el objeto JSON completo, mientras que **Datos_Clave** mantiene adicionalmente los puntos relevantes para consultas rápidas.

Esquema de la Base de Datos de Memoria

La memoria persistente se implementó en Airtable mediante la base:

BASE CODER IA AVANZADA

Tabla:Memoria_Agente

El esquema configurado es el siguiente:

Campo	Tipo	Función
Session_ID	Single line text	Identificador único de sesión y clave de aislamiento entre conversaciones.
Fecha_Actualizacion	Date / Time	Fecha y hora de la última actualización del registro.
User_Name	Single line text	Nombre o identificador legible del usuario.
Resumen_Consolidado	Long text	Objeto JSON persistente generado por el Summarizer.
Estado_Caso	Single select / text	Estado actual del caso, por ejemplo Nuevo o En seguimiento.
Datos_Clave	Long text	Indicadores y puntos relevantes extraídos de la conversación.
Cantidad_Mensajes	Number	Contador utilizado para determinar cuándo activar la summarization.

El circuito de lectura y escritura se encuentra correlacionado por Session_ID.

La lectura se realiza mediante Search Records utilizando una coincidencia exacta:

{Session_ID} = Session_ID entrante

Luego, un nodo IF verifica si existe memoria previa.

Para usuarios nuevos se crea un registro inicial. Para usuarios recurrentes se reutiliza el registro existente y se recuperan:

User_Name

Resumen_Consolidado

Estado_Caso

Datos_Clave

Cantidad_Mensajes

La actualización de memoria se realiza de manera idempotente sobre el mismo Record ID, evitando crear registros duplicados para una misma sesión.

El campo Resumen_Consolidado almacena el objeto estructurado:

```
{
  "asunto_principal": "Consulta comercial sobre planes",
  "puntos_clave": [
    "El usuario solicita información sobre los planes.",
    "Consultó precios y descuentos.",
    "Busca una opción económica."
  ],
  "accion_requerida": "Continuar asesoramiento sobre el plan más económico."
}
```

Antes de enviarlo al agente central, este JSON se transforma nuevamente en un contexto legible y se encapsula mediante:

[INICIO DE CONTEXTO COMPARTIDO]

Usuario: ...

Asunto principal: ...

Puntos clave: ...

Acción requerida: ...

Estado del caso: ...

[FIN DEL CONTEXTO COMPARTIDO]

Este diseño permite combinar una memoria reciente de corto plazo con memoria persistente externa, evitando guardar transcripciones completas, logs técnicos, HTML o payloads innecesarios.

